

Báo cáo deep research về Semi-Supervised Segmentation siêu âm với Mean Teacher + MambaU-Lite

Tóm tắt điều hành

Bài toán **semi-supervised segmentation (SSL)** cho **ảnh siêu âm** thường bị chi phối bởi 3 yếu tố: (i) **hiều speckle + artefact** làm biên mờ và khiến mô hình dễ “tin nhầm” pseudo-label; (ii) **đa hình thái tổn thương** (scale/shape) đòi hỏi **đa tỉ lệ + ngữ cảnh dài hạn**; (iii) **thiếu nhãn pixel-level** khiến các phương pháp teacher-student phải kiểm soát chất lượng consistency/pseudo-label. Các công trình BUS (breast ultrasound) và các kiến trúc Mamba cho segmentation đều nhấn mạnh các khó khăn này. ¹

Khung **Mean Teacher** (Tarvainen & Valpola, NeurIPS 2017) vẫn là “xương sống” SSL nhờ cơ chế **teacher = EMA của student**, tạo consistency target ổn định theo thời gian. ² Tuy nhiên, trong y tế/siêu âm, consistency “mù” thường gây **khuếch đại lỗi**, nên nhiều biến thể đưa vào **uncertainty filtering** (ví dụ UA-MT cho segmentation y khoa, tripled-uncertainty MT, residual-driven MT, PE-MT...). ³

MambaU-Lite (2024 arXiv; bản proceedings 2025) là backbone segmentation cực nhẹ (~400K tham số) và đã tích hợp sẵn **CBAM ở skip + ICSA ở bottleneck** (PCA/PSA). ⁴ Điểm mạnh là trộn **CNN (cục bộ) + VSS/SS2D kiểu VMamba (ngữ cảnh dài hạn, tuyến tính theo độ dài)**. ⁵ Đây là nền tốt để đem sang siêu âm, nơi các mô hình Mamba gần đây đã chứng minh hiệu quả khi kết hợp attention/đa tỉ lệ (ví dụ WDFFU-Mamba). ⁶

Khoảng trống lớn: **rất ít nghiên cứu “đúng nghĩa” kết hợp Mean Teacher + Mamba-based U-shape** trên siêu âm. Một số hướng gần có dấu hiệu hội tụ: (i) Mean Teacher + attention (UG-CEMT dùng cross-attention; UMT-ISE chèn SE/inception); (ii) Mamba-U-shape + dual-attention/wavelet; (iii) teacher-student cho BUS như RA-UGMT (breast US) và RA-BUSSeg (ICCV 2025). ⁷

Đề xuất ưu tiên thử nghiệm (theo “tác động / rủi ro kỹ thuật”): - Ưu tiên cao: **bottleneck kiểu “Mamba + đa tỉ lệ (ASPP/dilated)”** và **uncertainty-guided attention** (dùng chính teacher uncertainty để điều chế attention/consistency). Các ý này bám sát lý do DeepLab/atrous hiệu quả cho dense prediction và là “điểm đau” siêu âm (scale + biên mờ). ⁸

- Ưu tiên trung: **frequency/wavelet-gated attention** (gợi ý từ WDFFU-Mamba) để giảm nhạy cảm với speckle và cải thiện biên. ⁹

- Ưu tiên thăm dò: **so sánh thứ tự/kiểu ghép channel-spatial attention (sequential vs parallel vs residual)** vì gần đây có nghiên cứu chỉ ra việc chọn topology vẫn mang tính kinh nghiệm. ¹⁰

Bối cảnh kỹ thuật: Mean Teacher và nền MambaU-Lite trong bài toán siêu âm

Mean Teacher: teacher không học bằng gradient; nó được cập nhật bởi **EMA** từ tham số student sau mỗi bước. Bản gốc mô tả rõ quy trình: student chịu supervised loss (nếu có nhãn) + consistency loss so với teacher; teacher cập nhật bằng EMA theo hệ số làm mượt α . ¹¹

Điểm mấu chốt trong segmentation y khoa: **consistency target chỉ hữu ích nếu target đủ “đáng tin”**; vì vậy các biến thể về sau thường thêm **uncertainty map** để lọc/giảm trọng số vùng dự đoán kém chắc chắn. ¹²

Mamba/VMamba/VSS: Mamba là kiến trúc dựa trên **selective state space model** nhằm đạt **tuyến tính theo chiều dài chuỗi** và hiệu năng mạnh trên dữ liệu dài thông tin. ¹³ VMamba chuyển hoá Mamba sang thị giác bằng **VSS block + SS2D**, quét theo **4 hướng** để thu ngữ cảnh 2D hiệu quả. ¹⁴ Điều này giải thích vì sao các U-shape “Mamba-hoá” xuất hiện dày trong segmentation y khoa (ví dụ SegMamba; tài liệu MICCAI cũng nhắc U-Mamba như một hướng tích hợp Mamba vào nnU-Net). ¹⁵

MambaU-Lite làm gì đặc biệt ở bottleneck/skip?

Theo mô tả kiến trúc, MambaU-Lite: - Chuẩn hoá kênh đầu vào lên 16; qua encoder để tạo các mức kênh/tỉ lệ, rồi **ghép (concat) thành tensor bottleneck cỡ $256 \times H/16 \times W/16$** trước khi vào bottleneck. ¹⁶

- Skip connection dùng **CBAM** (channel + spatial attention dạng sequential). ¹⁷

- Bottleneck dùng **ICSA** gồm **2 PCA + 1 PSA**, lấy từ công trình “Priority Channel/Spatial Attention” (PCA/PSA). ¹⁸

- Khối **P-Mamba** là 2-nhánh: một nhánh DW conv + tách kênh qua 2 VSS rồi concat/IN/ReLU; nhánh còn lại AvgPool+MaxPool, concat rồi conv + sigmoid để tạo “attention-like scaling”; cuối cùng cộng hai nhánh. ¹⁹

Với siêu âm, các mô hình breast US gần đây cũng nhấn mạnh **speckle noise, artefact, biên mờ** và đề xuất **wavelet/dual-attention** hoặc backbone có modelling dài hạn (VSS/Mamba). ²⁰ Do đó, hướng “MambaU-Lite + Mean Teacher” là hợp lý, nhưng cần **thiết kế bottleneck/attention phù hợp** để consistency không tự phá.

Sơ đồ khái niệm Mean Teacher + MambaU-Lite (mang tính triển khai, không gắn dataset cụ thể):

```
flowchart LR
    X_l["Ảnh có nhãn x_l"] --> S["Student: MambaU-Lite (có noise/aug)"]
    X_u["Ảnh không nhãn x_u"] --> S
    S --> T["Teacher: EMA(Student) (noise/aug khác)"]
    T --> S

    S --> P_s["p_s (mask/logits)"]
    T --> P_t["p_t (mask/logits)"]

    Y["GT mask y_l"] --> L_sup["Supervised loss (Dice/CE)"]
    P_s --> L_sup

    P_s --> L_con["Consistency loss (lọc theo uncertainty)"]
```

```

P_t --> L_con

L_sup --> L_tot["L_total = L_sup + w(t)*L_con"]
L_con --> L_tot
L_tot --> UpdateS["Update student (SGD/AdamW)"]
UpdateS --> EMA["Update teacher:  $\theta_t = \alpha \theta_t + (1-\alpha) \theta_s$ "]
EMA --> T

```

Tổng hợp nghiên cứu liên quan cho Mean Teacher, MambaU-Lite và SSL segmentation trên siêu âm

Nhánh Mean Teacher & biến thể cho segmentation y khoa

Mean Teacher gốc giới thiệu “teacher = EMA weights” để tạo target ổn định và mở rộng tốt cho dữ liệu lớn/online. ²

Trong y khoa, UA-MT (Yu et al.) áp dụng teacher-student + **định lượng uncertainty** cho segmentation (ban đầu nổi bật ở bài toán Left Atrium 3D). ²¹

Sau đó xuất hiện nhiều cải tiến theo hướng “làm target tốt hơn / giảm bias / tăng ổn định”: - **Tripled-uncertainty guided Mean Teacher** nhấn mạnh consistency ở mức task/auxiliary và uncertainty đa nguồn; có bản MICCAI 2021 và bản journal MedIA. ²²

- **RDMT** (Residual-Driven Mean Teacher) đưa perturbation ở mức mô hình (residual perturbation) và biến thể Dice loss để cải thiện SSL segmentation. ²³

- **UMT-ISE** chèn **Inception + SE** vào khung uncertainty-aware MT để tăng biểu diễn (dù báo cáo trên CT đa cơ quan, ý tưởng block là hữu ích cho siêu âm). ²⁴

- **UG-CENT** (WACV 2025) kết hợp **cross-attention ensemble** + uncertainty-guided consistency, cho thấy lợi ích rõ khi chỉ dùng ~10% nhãn (bối cảnh MRI, nhưng cơ chế cross-attention gợi ý trực tiếp cho thiết kế attention trong teacher-student). ²⁵

- Các biến thể gần đây khác (PE-MT, PAMT, cross-training...) cũng tiếp tục xoay vào pseudo-label chất lượng và bias/coupling giữa teacher-student. ²⁶

Nhánh MambaU-Lite & hệ Mamba-segmentation

Mamba đặt nền selective SSM; VMamba đưa ra VSS+SS2D cho thị giác; Vision Mamba (Vim) nhấn mạnh backbone thị giác không cần self-attention dày đặc. ²⁷

Trong segmentation y khoa, SegMamba là ví dụ tiêu biểu cho “U-shape + Mamba” (3D) và thảo luận rõ động cơ thay transformer vì chi phí tính toán; tài liệu MICCAI cũng nhắc U-Mamba như hướng tích hợp Mamba vào nnU-Net. ²⁸

MambaU-Lite nổi bật vì cực nhẹ (~400K params) và có sẵn attention trong skip/bottleneck; kiến trúc và kích thước feature map được mô tả chi tiết trong bài. ²⁹

Nhánh SSL segmentation trên siêu âm (nhấn BUS nhưng không giới hạn)

Có các công trình semi-supervised siêu âm từ sớm (PLOS ONE 2014) cho thấy nhu cầu “semi-supervised” trong siêu âm đã tồn tại lâu. ³⁰

Giai đoạn gần đây tăng tốc, đặc biệt với **breast ultrasound**: - **RA-UGMT** (Computerized Medical Imaging and Graphics) dùng **uncertainty-guided Mean Teacher** và **residual + attention** cho segmentation u vú, đánh giá trên **BUSI và UDIAT** (2 bộ công khai). ³¹

- **PH-Net** (CVPR 2024) xây khung SSL cho BUS và so sánh với nhiều baseline SSL, trong đó có RA-UGMT. ³²

- **RA-BUSeg** (ICCV 2025) mô tả rõ **teacher-student** cho BUS với các module quan hệ (ARP/CRA) để khai

thác quan hệ pixel và alignment đa tầng. ³³

- Hướng “universal semi-supervised ultrasound segmentation” cũng xuất hiện (ProPL, 2025) với prompt-guided pseudo-labeling và uncertainty calibration. ³⁴

Tổng hợp thiết kế bottleneck và attention, cùng các biến thể đã dùng cho segmentation và y tế/siêu âm

Nhóm thiết kế bottleneck phổ biến (và cách “mang sang segmentation”)

ResNet bottleneck (1×1 giảm kênh $\rightarrow 3 \times 3 \rightarrow 1 \times 1$ tăng kênh) là khối chuẩn để tăng độ sâu với chi phí hợp lý; ResNet cũng được sử dụng rộng làm backbone cho segmentation (FCN/DeepLab/encoder-decoder). ³⁵

Inverted bottleneck (MobileNetV2) đảo ngược logic: **mở rộng kênh (expand)** $\rightarrow$ **depthwise conv** $\rightarrow$ **linear projection** (bottleneck mỏng ở input/output) và được báo cáo hữu ích cho cả classification/detection/segmentation (Mobile DeepLabv3). ³⁶

MobileNetV3 tiếp tục tinh chỉnh hướng mobile bằng NAS + cải tiến kiến trúc, đồng thời mô tả việc dùng **SE** như attention nhẹ trong bottleneck/expansion (và liên hệ với MnasNet). ³⁷

Dilated/atrous bottleneck & đa tỉ lệ:

- Dilated conv giúp mở receptive field mà không giảm resolution. ³⁸

- DeepLab đề xuất **ASPP** (nhiều nhánh atrous rate khác nhau) để bắt đa tỉ lệ. ³⁹

- DeepLabv3+ kết hợp pyramid pooling và decoder để phục hồi biên tốt hơn (thực tế rất gần “triết lý U-shape”), và dùng atrous separable conv để tiết kiệm chi phí. ⁴⁰

Bottleneck “gắn attention / dynamic receptive field”: thay vì chỉ tăng độ sâu, nhiều thiết kế dùng attention để “tập trung” kênh/vùng hoặc chọn receptive field theo ngữ cảnh (đặc biệt hữu ích trong siêu âm do vật thể nhiều scale + nền nhiễu). Ví dụ điển hình có SKNet (chọn kernel theo softmax attention) và GE (gather-excite) khai thác ngữ cảnh không gian rẻ. ⁴¹

Attention kênh (channel attention) và ứng dụng cho segmentation/siêu âm

SE (Squeeze-and-Excitation) là cơ chế chuẩn hoá kênh bằng squeeze global + excite gating, tăng hiệu năng CNN với overhead nhỏ. ⁴²

ECA giảm chi phí SE bằng 1D conv để tạo tương tác kênh cục bộ và nhấn mạnh việc tránh giảm chiều quá mạnh. ⁴³

GE (Gather-Excite) xem attention như “gom ngữ cảnh không gian rồi phân phối lại” với chi phí thấp. ⁴⁴

SK (Selective Kernel) tạo attention để chọn receptive field (đa kernel/đa rate) theo ngữ cảnh. ⁴⁵

Trong siêu âm, các ý tưởng tương tự đã được “đóng gói” thành mô hình chuyên biệt: ví dụ **SK-U-Net** cho segmentation u vú dùng attention để điều chỉnh receptive field và **trộn dilated + thường**, có báo cáo Dice tăng rõ so với U-Net thường. ⁴⁶

Attention không gian (spatial/global attention) và ứng dụng cho segmentation/siêu âm

CBAM kết hợp **channel attention + spatial attention theo dạng sequential** (nhẹ, dễ cắm vào CNN/U-Net).

Non-local block mô hình hoá phụ thuộc dài hạn bằng tổng có trọng số trên toàn vị trí. DANet đưa 2 nhánh attention: position attention + channel attention để tăng mIoU segmentation trên benchmark tự nhiên. Criss-Cross attention (CCNet) thu ngữ cảnh theo đường ngang/dọc, giảm memory so với non-local và vẫn tiến tới full-image context qua lặp. Axial attention factorize 2D attention thành 1D (theo trục), và Axial-DeepLab cho thấy lợi ích trong dense prediction với chi phí giảm.

Trong y tế/siêu âm, “attention gate” kiểu Attention U-Net là tiền lệ quan trọng vì gắn trực tiếp vào skip/decoder để lọc vùng không liên quan. Các biến thể SE/attention cho siêu âm cũng nở rộ: DSEU-net (SE-U-Net + deep supervision cho ultrasound segmentation), Dilated-SE-U-Net cho fetal ultrasound, và các mô hình dùng spatial attention/boundary cues trong BUS.

Các nghiên cứu kết hợp Mean Teacher hoặc MambaU-Lite với sửa bottleneck/attention

Bảng dưới đây tập trung vào các bài “đúng trọng tâm” của bạn: (a) Mean Teacher + cải tiến bottleneck/attention/uncertainty, và (b) Mamba-U-shape (gồm MambaU-Lite) + attention/đa tỉ lệ, ưu tiên có ultrasound dataset.

Hướng	Nghiên cứu	Dataset (US nếu có)	Kiến trúc / khối đáng chú ý	Kết quả/chốt ý chính (theo mô tả công bố)	Tham chiếu
Mean Teacher gốc	Mean Teacher (Tarvainen & Valpola)	(không chuyên y tế)	Teacher = EMA weights; supervised + consistency; công thức EMA & consistency cost	Đặt nền teacher–student EMA.	arXiv: 1703.01780
Mean Teacher + uncertainty	UA-MT (Yu et al.)	(MRI LA 3D)	Uncertainty-aware MT cho segmentation y khoa	Là “mốc” phổ biến cho nhánh uncertainty-guided MT.	arXiv: 1907.07034
Mean Teacher + attention/residual (US)	RA-UGMT (Farooq et al., CMIG)	BUSI + UDIAT (US)	Residual + attention U-Net backbone; uncertainty-guided consistency; MC sampling để ước lượng uncertainty	Báo cáo khai thác unlabeled giúp tăng chất lượng segmentation BUS; đánh giá trên 2 dataset công khai BUSI/UDIAT.	DOI: 10.1016/j.compmedimag. 2022.102173

Hướng	Nghiên cứu	Dataset (US nếu có)	Kiến trúc / khối đáng chú ý	Kết quả/chốt ý chính (theo mô tả công bố)	Tham chiếu
Teacher-student cho BUS (US)	RA-BUSSeg (ICCV 2025)	BUS (US)	Teacher-student cùng kiến trúc; module ARP + CRA để lan truyền quan hệ pixel và alignment đa tầng	Nêu rõ teacher-student framework cho BUS segmentation. ³³	ICCV 2025 OpenAccess PDF
Mean Teacher + cross-attention	UG-CEMT (WACV 2025)	(MRI)	Cross-attention ensemble MT + uncertainty-guided consistency + SAM (sharpness-aware)	Báo cáo lợi ích mạnh ở setting 10% labeled . ²⁵	arXiv: 2412.15380
Mean Teacher + SE/inception	UMT-ISE	(CT đa cơ quan)	Mean Teacher + Inception + SE block	Cho thấy cách “cắm” SE/inception vào teacher-student. ²⁴	Springer chapter
MT biến thể ổn định	RDMT	(medical chung)	Model-level residual perturbation + eDice	Nêu rõ cải tiến MT bằng perturbation/ Dice biến thể. ²³	MedIA/Elsevier (ScienceDirect)
MambaU-Lite (nền của bạn)	MambaU-Lite	(đang báo cáo trên da liễu)	VSS/SS2D theo VMamba; P-Mamba 2 nhánh; CBAM tại skip; ICSA (PCA/PSA) tại bottleneck ; ~400K params	Mô tả chi tiết size tensor và vị trí attention (skip/bottleneck). ⁵⁴	arXiv: 2412.01405
Mamba + attention (US)	WDDFU-Mamba	Breast US (2 dataset công khai)	“Wavelet-guided enhancement” + “dual-attention feature fusion” trong U-shaped Mamba	Báo cáo vượt nhiều baseline trên BUS. ⁵⁵	arXiv: 2512.17278
Mamba + VSS encoder (US)	Mamba-CNN + feature interaction (Sensors 2026)	Breast US	Dùng VSS làm encoder để bắt long-range; trộn CNN & “feature interaction”	Nêu rõ động cơ speckle/artefact và dùng VSS cho phụ thuộc dài hạn. ⁵⁶	DOI: 10.3390/s26010105

Hướng	Nghiên cứu	Dataset (US nếu có)	Kiến trúc / khối đáng chú ý	Kết quả/chốt ý chính (theo mô tả công bố)	Tham chiếu
MT + Mamba (gợi ý rất gần)	DSMT-Net	(medical chung; cần kiểm tra modality trong bài gốc)	Dual-student Mean Teacher: U-Net + Mamba-UNet như 2 student; pseudo-label pixel-level	Là dấu hiệu trực tiếp về "MT + Mamba-UNet". 57	Elsevier (Pattern Recognition Letters, theo ScienceDirect)

Nhận xét quan trọng từ bảng: hiện có **(1) MT trên BUS (RA-UGMT/RA-BUSeg)** và **(2) Mamba-U-shape trên BUS (WDFFU-Mamba, VSS encoder)**, nhưng **"MT + MambaU-Lite trên BUS"** vẫn là khoảng trống rõ ràng, phù hợp để bạn đóng góp novelty.

Đề xuất 3-5 thiết kế khối mới khả thi để thử nghiệm trong MambaU-Lite + Mean Teacher (siêu âm)

Giả định kỹ thuật (do bạn chưa chỉ định dataset/size): dùng input **1×H×W** hoặc **3×H×W** (tùy bạn chuẩn hoá kênh), resize **256×256** theo thực hành trong MambaU-Lite. 58 Khi đó bottleneck của MambaU-Lite có tensor xấp xỉ **B×256×16×16**. 16

Khối đề xuất 1: Mamba-ASPP Bottleneck đa tỉ lệ (MAB)

Động cơ: Siêu âm đòi hỏi đa tỉ lệ mạnh; ASPP là "điển hình" để gom ngữ cảnh đa tỉ lệ cho dense prediction. 59 Trong khi đó Mamba/VSS bắt phụ thuộc dài hạn tuyến tính. 60 Tách 2 nhánh (SSM + atrous multi-rate) giúp giảm rủi ro "một cơ chế gánh hết".

Sơ đồ khối (bottleneck)

```

flowchart TD
    IN["F: B×256×16×16"] --> N1["LN/IN"]
    N1 --> A1["Nhánh A: VSS × L (L∈{1,2})"]
    N1 --> B1["Nhánh B: ASPP-lite"]
    B1 --> B2["3×3 dilated DWConv r∈{1,2,4,8} (song song) + 1×1 fuse"]
    A1 --> C["Concat (A,B): B×(256+256)×16×16"]
    B2 --> C
    C --> P["1×1 PWConv → 256 kênh"]
    P --> G["ECA hoặc SE (tùy chọn)"]
    G --> OUT["Residual add với IN → B×256×16×16"]

```

Thông số cần sweep: dilation rates (mặc định {1,2,4,8}); L (số VSS khối); có/không có ECA/SE; kiểu normalize (IN vs LN) vì MambaU-Lite dùng InstanceNorm ở một số chỗ. 61

Vị trí chèn: thay ICSA hiện tại ở bottleneck hoặc song song với ICSA (ablation A/B). MambaU-Lite hiện dùng ICSA tại bottleneck nên việc thay thế/ghép cần ablation rõ. ⁵⁸

Khối đề xuất 2: Uncertainty-Guided Channel-Spatial Attention cho teacher-student (UG-CSA)

Động cơ: RA-UGMT cho BUS cho thấy **uncertainty-guided consistency** quan trọng vì pseudo target trên siêu âm dễ nhiễu. ⁶² Ý tưởng mới: dùng uncertainty không chỉ để “lọc loss”, mà còn để **điều chế attention** ngay trong bottleneck/skip (giảm khuếch đại nhiễu). Đây là biến thể “kết hợp MT với attention” tương tự tinh thần các MT cải tiến gần đây. ⁶³

Thiết kế: với feature $F_b = B \times 256 \times 16 \times 16$, tính uncertainty map $U = B \times 1 \times 16 \times 16$ từ teacher (ví dụ entropy của softmax hoặc MC variance). Sau đó: - Spatial gate: $A_s = \text{sigmoid}(\text{conv}(U)) \rightarrow$ nhân vào F_b
- Channel gate: $A_c = \text{ECA}(F_b \odot A_s)$ hoặc SE $\rightarrow$ nhân tiếp
- Output đưa vào decoder và đồng thời dùng A_s để **reweight consistency loss theo vùng**.

Siêu tham số: ngưỡng τ để “clip” U ; hệ số γ cho độ sắc sigmoid; weight schedule $w(t)$ của consistency (ramp-up). Mean Teacher gốc đã nhấn mạnh tính nhạy của consistency theo chất lượng target và có hệ số EMA α . ⁶⁴

Vị trí chèn: (a) bottleneck; (b) 1–2 skip deep nhất (nơi semantic giàu nhưng spatial thô). MambaU-Lite đã dùng CBAM ở skip; UG-CSA có thể thay CBAM ở các skip sâu nhất để tránh overhead toàn mạng. ¹⁷

Khối đề xuất 3: Frequency/Wavelet-Gated Attention (FW-Gate) cho speckle-robustness

Động cơ: Các kiến trúc BUS dựa trên Mamba gần đây đưa wavelet + dual-attention để nhạy biên hơn và ổn định hơn trước speckle. ⁶ FW-Gate nhằm “mượn” ý tưởng đó nhưng giữ nhẹ như MambaU-Lite.

Thiết kế nhẹ: thay vì wavelet đầy đủ trên ảnh, làm **wavelet-lite trên bottleneck** (16×16) hoặc trên stage H/8 (32×32) để chi phí thấp: - Tính 4 subband (LL/LH/HL/HH) bằng filter cố định (Haar) hoặc conv học được (nhẹ).
- Dùng năng lượng subband để tạo channel weight (nhấn biên/texture) và spatial mask (nhấn vùng chắc chắn).
- Fuse với ICSA hoặc thay PSA bằng “frequency-spatial attention”.

Vị trí chèn: ưu tiên bottleneck (nhẹ nhất), hoặc trước decoder để phục hồi biên.

Khối đề xuất 4: SK-Mamba Bottleneck (Dynamic Receptive Field + VSS)

Động cơ: SKNet và SK-U-Net cho thấy cơ chế “chọn receptive field” rất hợp với u vú (lesion nhỏ/khổng lồ). ⁶⁵ Kết hợp thêm VSS/Mamba để bắt quan hệ xa.

Thiết kế: - Nhánh K1: depthwise 3×3 (rate 1)
- Nhánh K2: depthwise 3×3 (rate 2 hoặc kernel 5×5)
- Nhánh K3: depthwise 3×3 (rate 4)
- Softmax gating (theo SKNet) để trộn nhánh; song song có 1 VSS block; concat và 1×1 project.

Chèn: bottleneck hoặc PE block ở encoder sâu (H/8, H/16). MambaU-Lite vốn đã dùng AxialDW kernel lớn (7×7) trong encoder/decoder; SK-Mamba là cách “động hoá” lựa chọn kernel/rate thay vì cố định. ⁶⁶

Khối đề xuất 5: Boundary-Enhanced Dual-Path Bottleneck (BE-DP)

Động cơ: Siêu âm bị biên mờ; nhiều bài BUS nhấn mạnh boundary ambiguity. ⁶⁷ Thiết kế dual-path: một path học “region semantics”, một path học “edge/boundary cues”.

Thiết kế: - Path SSM: $VSS \times 1-2$ (global)

- Path Edge: depthwise Sobel/Laplacian (fixed) + 3×3 conv + sigmoid tạo boundary attention

- Fuse: $F_{out} = F_{ssm} \odot (1 + A_{edge})$

Chèn: decoder gần output (để sharpen biên) hoặc bottleneck (để hướng decoder).

Kế hoạch thí nghiệm: dataset siêu âm công khai, protocol, ablation, compute budget và bảng so sánh

Datasets siêu âm công khai nên ưu tiên (giả định chưa chốt domain)

Breast Ultrasound: - **BUSI** (Data in Brief): dataset siêu âm vú phổ biến, có nhãn và được trích dẫn rộng. ⁶⁸

- **UDIAT / Dataset B** (được mô tả trong IEEE JBHI Yap et al.): gồm **163 ảnh (53 malignant, 110 benign)** và được dùng rộng trong BUS literature; đôi khi cần thỏa thuận cấp phép. ⁶⁹

- **BUSIS benchmark** (562 ảnh, nhiều bác sĩ tham gia annotation, phục vụ đánh giá khách quan). ⁷⁰

- Các bộ BUS mới hơn (ví dụ BUS-UCLM có masks RGB và mô tả rõ). ⁷¹

Cardiac / fetal / thyroid: - **CAMUS**: dataset siêu âm tim lớn (500 bệnh nhân) cho segmentation & chỉ số lâm sàng, mô tả trong bài giới thiệu dataset. ⁷²

- **HC18**: dataset đo chu vi đầu thai nhi, **1334 ảnh 2D** theo trang challenge/Zenodo. ⁷³

- **TN3K**: thyroid nodule US segmentation dataset **3493 ảnh** (được mô tả trực tiếp trong bài TRFE-Net). ⁷⁴

Nếu bạn muốn “đa domain siêu âm” để kiểm tra tổng quát hoá: **US-43d** gom **43 dataset và >280k cặp ảnh-mask**, dùng cho pretrained/foundation; phù hợp cho pretraining hoặc kiểm thử transfer. ⁷⁵

Chia labeled/unlabeled và thiết lập SSL (gợi ý thực nghiệm)

Do dataset cụ thể chưa chỉ định, gợi ý một protocol “chuẩn bài” để dễ so sánh với literature: - Tỷ lệ nhãn: **5% / 10% / 20% labeled**, phần còn lại unlabeled; chạy **3 seeds** để báo cáo mean±std. (Setting 10% labeled thường được các bài MT/teacher–student nhắc như mốc quan trọng). ²⁵

- Split theo bệnh nhân (nếu metadata có), đặc biệt CAMUS. ⁷⁶

Metrics và tiêu chí đánh giá

Khuyến nghị báo cáo song song: - **Dice** và **IoU** cho overlap (chuẩn segmentation).

- **HD95 (Hausdorff 95%)** hoặc boundary distance để phản ánh chất lượng biên (quan trọng với siêu âm). HD95 là metric phổ biến trong segmentation y khoa (ví dụ pipeline SegMamba cũng nhắc Dice/HD95 khi chấm metric). ⁷⁷

Training protocol cho Mean Teacher + MambaU-Lite (khuyến nghị thực dụng)

Giữ gần “baseline chuẩn” để ablation có ý nghĩa: - Optimizer: Adam/AdamW (MambaU-Lite báo cáo dùng Adam). ⁵⁸

- EMA α : sweep {0.99, 0.995, 0.999}; Mean Teacher mô tả α là hyperparameter quan trọng trong EMA update. ⁷⁸

- Consistency weight $w(t)$: ramp-up ($0 \rightarrow \lambda_u$) trong 10–30% đầu epoch; các biến thể uncertainty-guided MT thường cần schedule để tránh “đề” supervised khi teacher còn yếu. (Tinh thần này xuyên suốt các bài uncertainty-guided MT). ⁷⁹

- Augmentation: weak/strong aug cho student-teacher (đặc biệt nếu bạn muốn cạnh tranh các SSL mạnh như PH-Net/RA-BUSeg, vốn nhấn mạnh robustness trước perturbation). ⁸⁰

Ablation study tối thiểu để chứng minh “khối mới” có giá trị

Đề xuất ma trận ablation (ngắn nhưng “đủ chặt”): - Baseline A: MambaU-Lite (giữ CBAM skip + ICSA bottleneck). ¹⁷

- Baseline B: MambaU-Lite + Mean Teacher (không thêm block mới). ⁷⁸

- Ablation nhóm Bottleneck: thay ICSA bằng (MAB / SK-Mamba / BE-DP), hoặc ghép song song.

- Ablation nhóm Attention: CBAM $\rightarrow$ (ECA / SE / GE / SCSEA) ở skip sâu; lưu ý nghiên cứu gần đây cho thấy “thứ tự channel-spatial” có thể ảnh hưởng mạnh, nên thử 2 topology (sequential vs parallel) ít nhất ở 1–2 vị trí. ¹⁰

- Ablation nhóm Uncertainty: chỉ lọc loss vs lọc loss + điều chế attention (UG-CSA).

Compute budget và timeline thí nghiệm

Biểu đồ phân bổ ngân sách (ví dụ theo % tổng GPU-hours; bạn có thể thay bằng số thực tế):

```
pie title Phân bổ ngân sách compute (đề xuất)
  "Baseline + tái hiện (A/B)" : 20
  "Sweep hyperparameter (EMA  $\alpha$ ,  $w(t)$ )" : 15
  "Ablation bottleneck (5 khối  $\times$  2 seeds)" : 35
  "Ablation attention (SE/ECA/CBAM topology)" : 15
  "Huấn luyện cuối + báo cáo (3 seeds)" : 15
```

Gantt timeline (giả sử 6 tuần, có thể co giãn):

```
gantt
  title Timeline thí nghiệm MambaU-Lite + Mean Teacher (đề xuất)
  dateFormat YYYY-MM-DD
  axisFormat %d/%m

  section Chuẩn bị
  Chuẩn hoá dataset + split SSL           :a1, 2026-02-12, 7d
  Baseline MambaU-Lite (supervised)       :a2, after a1, 5d
  Baseline Mean Teacher (B)               :a3, after a2, 5d
```

section Khối mới

MAB (Mamba-ASPP) + sweep :b1, after a3, 7d

UG-CSA (uncertainty-gated attention) :b2, after b1, 7d

Frequency/Wavelet gate :b3, after b2, 6d

SK-Mamba + BE-DP :b4, after b3, 6d

section Tổng hợp

Chạy 3 seeds cấu hình tốt nhất :c1, after b4, 7d

Viết báo cáo + bảng so sánh :c2, after c1, 4d

Bảng so sánh tóm tắt (khối/attention) với ưu nhược điểm và nguồn

Hạng mục	Ưu điểm chính	Nhược điểm/rủi ro	Khi nào nên dùng trong siêu âm	Nguồn
ResNet bottleneck	Hiệu quả tham số, dễ huấn luyện sâu	Không tự có đa tỉ lệ/attention; cần bổ sung	Encoder backbone hoặc thay conv block	He et al. CVPR 2016 ⁸¹
Inverted bottleneck	Rất hợp mobile; dùng depthwise để giảm FLOPs; có nhánh ứng dụng segmentation	Có thể yếu nếu biên rất mờ; cần attention/đa tỉ lệ	Khi cần model nhỏ, inference nhanh	MobileNetV2 ³⁶
Dilated/ASPP bottleneck	Bắt đa tỉ lệ tốt cho dense prediction	Chọn rate sai dễ “rỗng mẫu”/mất local detail	BUS/thyroid/fetal có scale thay đổi mạnh	DeepLab/ASPP, Yu & Koltun ⁸²
SE (channel)	Nhẹ, phổ biến, cải thiện ổn định	Có thể “quá global” nếu cấu trúc nhỏ	Khi muốn gain nhanh, overhead nhỏ	SE ⁸³
ECA (channel)	Nhẹ hơn SE, tránh giảm chiều	Kernel size cần chọn hợp lý	Khi model rất nhỏ (như MambaU-Lite)	ECA ⁸⁴
GE (context)	Gom ngữ cảnh không gian rẻ	Có thể kém với quan hệ phức tạp	Khi cần “context boost” nhẹ	GE ⁸⁵
SK (dynamic RF)	Chọn receptive field theo scale	Overhead nhánh; tuning phức tạp	BUS lesions đa scale; đã có tiền lệ SK-U-Net	SKNet + SK-U-Net ⁶⁵

Hạng mục	Ưu điểm chính	Nhược điểm/rủi ro	Khi nào nên dùng trong siêu âm	Nguồn
CBAM (channel+spatial)	Dễ cắm vào U-Net/skip; cân bằng nhẹ	Thứ tự CA→SA có thể không tối ưu mọi bài	Skip attention cho siêu âm; MambaU-Lite dùng sẵn	CBAM ⁸⁶
Non-local / DANet / CCNet	Bắt phụ thuộc dài hạn, tăng chất lượng segmentation	Tốn compute/memory (non-local); phức tạp triển khai	Chỉ dùng ở bottleneck hoặc tỉ lệ nhỏ	Non-local, DANet, CCNet ⁸⁷
Axial attention / Axial-DeepLab	Long-range với chi phí giảm nhờ factorization	Vẫn nặng hơn CNN-attention nhẹ	Nếu cần global context nhưng GPU hạn chế	Axial Attention, Axial-DeepLab ⁸⁸
Mean Teacher	Khai thác unlabeled ổn; chuẩn hoá SSL	Nhạy pseudo-label sai; cần uncertainty/filter	Nếu bạn có nhiều unlabeled siêu âm	Mean Teacher ⁷⁸
Uncertainty-guided MT (BUS)	Giảm khuếch đại lỗi; hợp siêu âm biên mờ	Cần ước lượng uncertainty (tăng chi phí)	BUS/siêu âm nói chung	RA-UGMT ⁶²
MambaU-Lite	Rất nhẹ; có sẵn CBAM+ICSA; có VSS/SS2D	Chưa “đo ni đóng giày” cho siêu âm; cần sửa bottleneck/attention	Khi cần model nhỏ + ngữ cảnh dài	MambaU-Lite ⁸⁹

Khoảng trống nghiên cứu và đề xuất ưu tiên thử nghiệm

Khoảng trống “đáng publish” nhất (nếu bạn muốn đóng góp học thuật): - **Kết hợp có hệ thống giữa MambaU-Lite (VSS) và Mean Teacher cho siêu âm**: hiện có teacher-student ở BUS (RA-UGMT/RA-BUSSeg) ⁹⁰ và có Mamba-US segmentation mạnh (WDFFU-Mamba, VSS encoder) ⁶, nhưng thiếu nghiên cứu “MT + backbone Mamba-lite + thiết kế attention/bottleneck chuyên siêu âm”. - **Thiết kế attention có xét uncertainty**: literature MT cho BUS cho thấy uncertainty là điểm mấu chốt ⁶²; còn literature attention nói chung đang quay lại câu hỏi “ghép channel-spatial thể nào là đúng” ¹⁰. Cơ hội: chứng minh rằng “uncertainty-guided attention topology” tốt hơn CBAM/ICSA cố định trong SSL.

Ưu tiên thử nghiệm (thực dụng): 1) **UG-CSA (uncertainty điều chế attention + consistency)** vì bám sát thất bại phổ biến nhất của MT trên siêu âm (pseudo-label sai). ⁹¹

2) **MAB (Mamba + ASPP-lite)** vì xử lý trực tiếp đa scale, đã có tiền lệ mạnh trong dense prediction (ASPP) và phù hợp đặc tính BUS/thyroid/fetal. ⁹²

3) **Frequency/Wavelet gate** nếu bạn thấy mô hình nhạy speckle/artefact; đây là pattern đã xuất hiện trong

Mamba-BUS gần đây. ⁶

4) **SK-Mamba** nếu lesion scale thay đổi mạnh (BUSI/UDIAT/BUSIS). ⁹³

¹ ²⁰ ⁵⁶ <https://www.mdpi.com/1424-8220/26/1/105>

<https://www.mdpi.com/1424-8220/26/1/105>

² ¹¹ ⁶⁴ ⁷⁸ https://proceedings.neurips.cc/paper_files/paper/2017/file/68053af2923e00204c3ca7c6a3150cf7-Paper.pdf

https://proceedings.neurips.cc/paper_files/paper/2017/file/68053af2923e00204c3ca7c6a3150cf7-Paper.pdf

³ ¹² ²¹ <https://arxiv.org/pdf/1907.07034>

<https://arxiv.org/pdf/1907.07034>

⁴ ¹⁶ ¹⁷ ¹⁸ ¹⁹ ²⁹ ⁵⁴ ⁵⁸ ⁶¹ ⁶⁶ ⁸⁹ <https://arxiv.org/pdf/2412.01405>

<https://arxiv.org/pdf/2412.01405>

⁵ ¹⁴ ⁶⁰ <https://arxiv.org/abs/2401.10166>

<https://arxiv.org/abs/2401.10166>

⁶ ⁹ ⁵⁵ <https://arxiv.org/abs/2512.17278>

<https://arxiv.org/abs/2512.17278>

⁷ ²⁵ ⁶³ https://openaccess.thecvf.com/content/WACV2025/papers/Karri_Uncertainty-Guided_Cross_Attention_Ensemble_Mean_Teacher_for_Semi-Supervised_Medical_Image_WACV_2025_paper.pdf

https://openaccess.thecvf.com/content/WACV2025/papers/Karri_Uncertainty-Guided_Cross_Attention_Ensemble_Mean_Teacher_for_Semi-Supervised_Medical_Image_WACV_2025_paper.pdf

⁸ ³⁹ ⁵⁹ ⁸² ⁹² <https://arxiv.org/abs/1606.00915>

<https://arxiv.org/abs/1606.00915>

¹⁰ <https://arxiv.org/abs/2601.07310v1>

<https://arxiv.org/abs/2601.07310v1>

¹³ ²⁷ <https://arxiv.org/abs/2312.00752>

<https://arxiv.org/abs/2312.00752>

¹⁵ https://link.springer.com/chapter/10.1007/978-3-031-72111-3_54

https://link.springer.com/chapter/10.1007/978-3-031-72111-3_54

²² https://link.springer.com/chapter/10.1007/978-3-030-87196-3_42

https://link.springer.com/chapter/10.1007/978-3-030-87196-3_42

²³ <https://www.sciencedirect.com/science/article/pii/S0933365723002713>

<https://www.sciencedirect.com/science/article/pii/S0933365723002713>

²⁴ https://link.springer.com/chapter/10.1007/978-3-031-23911-3_22

https://link.springer.com/chapter/10.1007/978-3-031-23911-3_22

²⁶ <https://www.mdpi.com/2306-5354/12/5/453>

<https://www.mdpi.com/2306-5354/12/5/453>

²⁸ <https://arxiv.org/abs/2401.13560>

<https://arxiv.org/abs/2401.13560>

- ³⁰ <https://journals.plos.org/plosone/article?id=10.1371%2Fjournal.pone.0100972>
<https://journals.plos.org/plosone/article?id=10.1371%2Fjournal.pone.0100972>
- ³¹ ⁶² ⁷⁹ ⁹⁰ ⁹¹ <https://www.sciencedirect.com/science/article/pii/S0895611122001434>
<https://www.sciencedirect.com/science/article/pii/S0895611122001434>
- ³² ⁶⁷ ⁸⁰ https://openaccess.thecvf.com/content/CVPR2024/papers/Jiang_PH-Net_Semi-Supervised_Breast_Lesion_Segmentation_via_Patch-wise_Hardness_CVPR_2024_paper.pdf
https://openaccess.thecvf.com/content/CVPR2024/papers/Jiang_PH-Net_Semi-Supervised_Breast_Lesion_Segmentation_via_Patch-wise_Hardness_CVPR_2024_paper.pdf
- ³³ https://openaccess.thecvf.com/content/ICCV2025/papers/Zhang_RA-BUSeg_Relation-aware_Semi-supervised_Breast_Ultrasound_Image_Segmentation_via_Adjacent_Propagation_ICCV_2025_paper.pdf
https://openaccess.thecvf.com/content/ICCV2025/papers/Zhang_RA-BUSeg_Relation-aware_Semi-supervised_Breast_Ultrasound_Image_Segmentation_via_Adjacent_Propagation_ICCV_2025_paper.pdf
- ³⁴ <https://arxiv.org/abs/2511.15057>
<https://arxiv.org/abs/2511.15057>
- ³⁵ ⁸¹ https://openaccess.thecvf.com/content_cvpr_2016/papers/He_Deep_Residual_Learning_CVPR_2016_paper.pdf
https://openaccess.thecvf.com/content_cvpr_2016/papers/He_Deep_Residual_Learning_CVPR_2016_paper.pdf
- ³⁶ https://openaccess.thecvf.com/content_cvpr_2018/papers/Sandler_MobileNetV2_Inverted_Residuals_CVPR_2018_paper.pdf
https://openaccess.thecvf.com/content_cvpr_2018/papers/Sandler_MobileNetV2_Inverted_Residuals_CVPR_2018_paper.pdf
- ³⁷ https://openaccess.thecvf.com/content_ICCV_2019/papers/Howard_Searching_for_MobileNetV3_ICCV_2019_paper.pdf
https://openaccess.thecvf.com/content_ICCV_2019/papers/Howard_Searching_for_MobileNetV3_ICCV_2019_paper.pdf
- ³⁸ <https://arxiv.org/abs/1511.07122>
<https://arxiv.org/abs/1511.07122>
- ⁴⁰ <https://arxiv.org/abs/1802.02611>
<https://arxiv.org/abs/1802.02611>
- ⁴¹ ⁴⁵ ⁶⁵ <https://arxiv.org/abs/1903.06586>
<https://arxiv.org/abs/1903.06586>
- ⁴² ⁸³ <https://arxiv.org/abs/1709.01507>
<https://arxiv.org/abs/1709.01507>
- ⁴³ ⁸⁴ <https://arxiv.org/abs/1910.03151>
<https://arxiv.org/abs/1910.03151>
- ⁴⁴ ⁸⁵ <https://arxiv.org/abs/1810.12348>
<https://arxiv.org/abs/1810.12348>
- ⁴⁶ ⁹³ <https://www.sciencedirect.com/science/article/pii/S174680942030183X>
<https://www.sciencedirect.com/science/article/pii/S174680942030183X>
- ⁴⁷ ⁸⁶ <https://arxiv.org/abs/1807.06521>
<https://arxiv.org/abs/1807.06521>

- 48 87 <https://arxiv.org/abs/1711.07971>
<https://arxiv.org/abs/1711.07971>
- 49 <https://arxiv.org/abs/1809.02983>
<https://arxiv.org/abs/1809.02983>
- 50 <https://arxiv.org/abs/1811.11721>
<https://arxiv.org/abs/1811.11721>
- 51 <https://arxiv.org/abs/2003.07853>
<https://arxiv.org/abs/2003.07853>
- 52 <https://arxiv.org/abs/1804.03999>
<https://arxiv.org/abs/1804.03999>
- 53 <https://www.sciencedirect.com/science/article/pii/S0957417423004402>
<https://www.sciencedirect.com/science/article/pii/S0957417423004402>
- 57 <https://www.sciencedirect.com/science/article/pii/S1476927125002403>
<https://www.sciencedirect.com/science/article/pii/S1476927125002403>
- 68 <https://www.sciencedirect.com/science/article/pii/S2352340919312181>
<https://www.sciencedirect.com/science/article/pii/S2352340919312181>
- 69 <https://pure.aber.ac.uk/ws/files/28421096/08003418.pdf>
<https://pure.aber.ac.uk/ws/files/28421096/08003418.pdf>
- 70 <https://arxiv.org/abs/1801.03182>
<https://arxiv.org/abs/1801.03182>
- 71 <https://www.nature.com/articles/s41597-025-04562-3.pdf>
<https://www.nature.com/articles/s41597-025-04562-3.pdf>
- 72 76 <https://arxiv.org/abs/1908.06948>
<https://arxiv.org/abs/1908.06948>
- 73 <https://hc18.grand-challenge.org/>
<https://hc18.grand-challenge.org/>
- 74 <https://www.sciencedirect.com/science/article/pii/S0010482522010976>
<https://www.sciencedirect.com/science/article/pii/S0010482522010976>
- 75 <https://link.springer.com/article/10.1007/s11548-025-03517-8>
<https://link.springer.com/article/10.1007/s11548-025-03517-8>
- 77 <https://github.com/ge-xing/SegMamba>
<https://github.com/ge-xing/SegMamba>
- 88 <https://arxiv.org/abs/1912.12180>
<https://arxiv.org/abs/1912.12180>